基于扰动不变生态位匹配的空间扰动响应预测方法

1 方法

1.1 方法概述

本文提出一种用于空间转录组扰动响应预测的生成式框架，称为 **NicheFlow**，即**扰动不变生态位匹配潜在流模型**（Perturbation-Invariant Niche-Matched Latent Flow）。该方法旨在预测空间组织状态在基因扰动或药物扰动后的转录组响应，同时保留组织空间结构、局部微环境以及生态位依赖的扰动传播模式。

给定一个包含 N 个空间 spot 和 G 个基因的空间转录组样本，记归一化后的表达矩阵为

$$X \in \mathbb{R}^{N \times G},$$

空间坐标为

$$S \in \mathbb{R}^{N \times d_s},$$

其中 $d_s = 2$ 表示二维组织切片，$d_s = 3$ 表示三维或连续切片空间坐标。每个 spot 具有扰动标签

$$y_i \in \{0, p_1, \ldots, p_K\},$$

其中 $y_i = 0$ 表示 control 或未扰动状态，$y_i = p$ 表示 spot i 携带扰动 p，例如 sgRNA 捕获标签、成像获得的扰动标签，或其他扰动注释。

空间扰动转录组数据的一个关键特点是：control spot 和 treated spot 可以同时存在于同一张组织切片中，但这并不意味着它们是同一个 spot 的 before–after 成对观测。换言之，同一张切片中的 control 和 treated spot 是同片共存的未配对样本，而不是同一细胞或同一 spot 在扰动前后的直接测量。因此，本文不假设存在 spot-level paired counterfactual ground truth，而是学习在相似组织上下文下，从 control 分布到扰动后分布的条件转移。

本文方法包含四个核心模块：

1. 表达潜在编码器，用于将高维基因表达压缩到低维潜在空间；
2. 扰动不变匹配模块，用于在 control spot 和 perturbation-labeled spot 之间构建生态位匹配的 pseudo-counterfactual coupling；
3. 泄漏控制的空间图 Transformer，用于编码局部空间邻域、组织边界和生态位上下文；

4. 条件潜在残差流模型，用于生成扰动诱导的潜在响应场，并可选地在推理阶段使用生物先验进行 Best-of-K reranking。

对于一个 control spot i 和目标扰动 p，模型预测其反事实扰动响应：

$$\hat{x}_i^p = f_\theta(x_i^0, s_i, p, \mathcal{N}_i, \mathcal{G}_{\text{bio}}),$$

其中 x_i^0 为 control 表达，s_i 为空间坐标，$\mathcal{N}_i$ 表示局部空间生态位，$\mathcal{G}_{\text{bio}}$ 表示可选生物先验，例如基因调控网络、扰动差异表达 signature 或通路注释。

1.2 数据设定与基本假设

空间扰动转录组数据通常包含 control spot 和扰动标记 spot。扰动状态可以由 sgRNA 捕获、成像标签或扰动特异性注释定义。然而，这些观测并不是同一 spot 的扰动前后成对测量。因此，本文将空间扰动预测问题分为三种数据设定：

1. **Spot-level paired data**：同一个 spot 同时具有扰动前和扰动后的观测。这种情况在空间转录组中非常少见。

2. **Same-slide unpaired data**：control spot 和 perturbation-labeled spot 共存于同一张组织切片，但不存在 spot-level before–after pairing。

3. **Cross-slide unpaired data**：control 和 treated 状态来自不同切片、不同动物、不同病人或不同批次。

本文主要针对第二种设定，即 same-slide unpaired spatial perturbation data。我们假设在给定观测到的组织上下文变量后，例如细胞类型、组织区域、生态位、空间坐标、组织病理特征、slide ID 和 donor/batch covariates，perturbation-labeled spots 可以作为 matched control spots 的反事实扰动分布样本。基于这一假设，本文学习的是**匹配后的分布转移**，而不是某一个具体 spot 的个体因果效应。

对于扰动 p，定义 control spot 集合为

$$\mathcal{C} = \{i : y_i = 0\},$$

扰动标记 spot 集合为

$$\mathcal{T}_p = \{j : y_j = p\}.$$

目标是在给定 control spot $i \in \mathcal{C}$ 的情况下，生成其在扰动 p 下的反事实表达分布：

$$x_i^0 \longrightarrow \hat{x}_i^p.$$

1.3 表达潜在编码器

空间转录组数据具有高维、稀疏和噪声大的特点，直接在原始表达空间中建模扰动转移较为困难。因此，本文首先学习一个低维表达潜在空间。该模块可以实现为变分自编码器，也可以在最小实现中使用普通自编码器。

对于每个 spot i，VAE encoder 将表达向量 $x_i \in \mathbb{R}^G$ 映射为潜在分布：

$$q_\phi(z_i \mid x_i) = \mathcal{N}\left(\mu_\phi(x_i), \mathrm{diag}(\sigma_\phi^2(x_i))\right),$$

其中

$$z_i \in \mathbb{R}^{d_z}.$$

通过重参数化技巧采样：

$$z_i = \mu_\phi(x_i) + \sigma_\phi(x_i) \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I).$$

decoder 将潜在表示重构回表达空间：

$$\hat{x}_i = D_\psi(z_i).$$

对于 log-normalized expression，可采用 L_1 或 Gaussian reconstruction loss：

$$\mathcal{L}_{\mathrm{rec}} = \sum_{i=1}^{N} \|x_i - \hat{x}_i\|_1.$$

VAE 的训练目标为：

$$\mathcal{L}_{\mathrm{VAE}} = \mathcal{L}_{\mathrm{rec}} + \lambda_{\mathrm{KL}} D_{\mathrm{KL}}\left(q_\phi(z_i \mid x_i) \,\|\, \mathcal{N}(0, I)\right).$$

预训练后，encoder 为所有 spot 生成潜在表示：

$$Z = E_\phi(X) = [z_1, \ldots, z_N]^\top \in \mathbb{R}^{N \times d_z}.$$

对于 control spot i，记其潜在状态为 z_i^0；对于携带扰动 p 的 spot j，记其潜在状态为 z_j^p。

需要强调的是,表达潜在表示 z_i 可以包含扰动响应信息,因为它用于定义扰动后的目标 residual；而后文中的匹配表示 u_i 必须尽量去除扰动响应信息，仅用于构建 control–treated matching。

1.4 扰动不变匹配表示

same-slide unpaired 数据的核心困难是：control spot 和 perturbation-labeled spot 没有真实配对关系。若直接使用扰动后的表达潜在表示 z_j^p 进行 matching，可能会引入偏差。原因是强响应 treated spot 的表达状态可能显著偏离其原始组织身份，从而导致 matching 过程更倾向于选择弱响应 treated spot。

为避免该问题，本文将用于 matching 的表示与用于生成扰动响应的表示分离。我们定义扰动不变匹配表示：

$$u_i = E_{\text{match}}(x_{i,\mathcal{G}_{\text{inv}}}, s_i, r_i, n_i, q_i, a_i),$$

其中 $\mathcal{G}_{\text{inv}}$ 表示扰动不敏感或组织身份相关基因集合，s_i 是空间坐标，r_i 是组织区域标签，n_i 是生态位标签，q_i 表示 slide、batch 或 donor covariate，a_i 表示其他可用注释，例如细胞类型或组织病理特征。

扰动不敏感基因集合可以定义为：

$$\mathcal{G}_{\text{inv}} = \{g : g \notin \mathcal{D}_p,\ g \notin \mathcal{T}(p),\ \text{Var}_p(\Delta x_g) < \delta\},$$

其中 $\mathcal{D}_p$ 是已知扰动响应基因集合，$\mathcal{T}(p)$ 是扰动基因 p 的调控靶基因集合，$\text{Var}_p(\Delta x_g)$ 表示基因 g 在不同扰动条件下的响应方差。

如果没有可靠的 perturbation signature 或 GRN 信息，也可以使用稳定表达基因、细胞类型 marker、组织区域 marker、空间坐标、组织病理特征或 control-only 训练得到的低维表达表示来构建 u_i。

为了进一步减少 u_i 中的扰动信息，可以加入对抗扰动去除约束。设扰动分类器为 D_{pert}，则通过 gradient reversal 训练：

$$\min_{E_{\text{match}}} \max_{D_{\text{pert}}} \sum_i \text{CE}(D_{\text{pert}}(u_i), y_i).$$

该约束鼓励 u_i 保留组织身份和生态位信息，同时降低其对扰动标签的可预测性。

因此，本文中 z_i 和 u_i 扮演不同角色：

1. z_i 是 response-aware latent representation，用于构建 residual target 和生成扰动响应；

2. u_i 是 matching representation，仅用于 control–treated pseudo-counterfactual 匹配。

1.5 生态位匹配的伪反事实耦合

对于每个 control spot $i \in \mathcal{C}$ 和目标扰动 p，本文在扰动标记集合 $\mathcal{T}_p$ 中构建一个 soft coupling distribution。matching 不基于 response-aware latent z，而基于扰动不变表示 u。

定义 matching distance：

$$d_{\text{match}}(i,j) = \alpha_u \|u_i - u_j\|_2^2 + \alpha_s \|s_i - s_j\|_2^2 + \alpha_r \mathbb{I}(r_i \neq r_j) + \alpha_n \mathbb{I}(n_i \neq n_j) + \alpha_q \mathbb{I}(q_i \neq q_j),$$

其中 $\alpha_u, \alpha_s, \alpha_r, \alpha_n, \alpha_q$ 为超参数。这里 q_i 表示 batch、slide 或 donor covariate。注意本文使用 b_{ij} 专门表示 tissue boundary crossing indicator，因此不使用 b_i 表示 batch covariate，以避免符号混淆。

在 same-niche prediction 中，候选 treated set 可限制为相同或相近生态位：

$$\mathcal{T}_p(i) = \{j \in \mathcal{T}_p : r_j = r_i,\ n_j = n_i\}.$$

soft coupling distribution 定义为：

$$\pi_p(j \mid i) = \frac{\exp(-d_{\text{match}}(i,j)/\tau)}{\sum_{j' \in \mathcal{T}_p(i)} \exp(-d_{\text{match}}(i,j')/\tau)},$$

其中 τ 是 temperature parameter。

对于 cross-niche prediction，不再采用 hard same-niche constraint，而是令

$$\mathcal{T}_p(i) = \mathcal{T}_p,$$

并通过 soft niche distance penalty 处理生态位差异：

$$d_{\text{match}}^{\text{cross}}(i,j) = \alpha_u \|u_i - u_j\|_2^2 + \alpha_s \|s_i - s_j\|_2^2 + \alpha_n d_{\text{niche}}(n_i, n_j) + \alpha_r d_{\text{region}}(r_i, r_j) + \alpha_q \mathbb{I}(q_i \neq q_j).$$

对于一个 pseudo-pair (i,j)，定义 matched counterfactual residual：

$$\Delta z_{ij}^p = z_j^p - z_i^0.$$

该 residual 不是同一 spot 的真实 before–after residual，而是在扰动不变组织身份匹配后，从 control latent state 到 perturbation-labeled latent state 的分布转移样本。

1.6 可选最优传输耦合

对于 cross-slide 或弱匹配的 same-slide 数据，可以使用熵正则化最优传输替代局部 soft matching。设 $\mu_{\mathcal{C}}$ 为 control spot 的经验分布，$\nu_{\mathcal{T}_p}$ 为扰动标记 spot 的经验分布，求解：

$$\pi_p^* = \arg\min_{\pi \in \Pi(\mu_{\mathcal{C}}, \nu_{\mathcal{T}_p})} \sum_{i,j} \pi_{ij} d_{\text{match}}(i,j) + \epsilon \sum_{i,j} \pi_{ij} \log \pi_{ij},$$

其中 $\Pi(\mu_{\mathcal{C}}, \nu_{\mathcal{T}_p})$ 表示具有给定边缘分布的 coupling 集合。

在主实现中，为了降低复杂度，优先采用 same-slide soft matching；最优传输作为 cross-slide generalization 或 ablation 设置。

1.7 空间图构建

为了编码空间邻域和组织结构，本文构建空间图：

$$\mathcal{G}_{\text{sp}} = (\mathcal{V}, \mathcal{E}_{\text{sp}}),$$

其中每个节点对应一个 spot。边通过空间坐标上的 k 近邻构建：

$$(i,j) \in \mathcal{E}_{\text{sp}} \quad \text{if} \quad j \in \text{kNN}(i; S).$$

每条边 (i,j) 的空间特征定义为：

$$e_{ij}^{\text{sp}} = \left[\|s_i - s_j\|_2, s_j - s_i, \text{RBF}(\|s_i - s_j\|_2) \right].$$

如果有组织区域或生态位标签，则加入：

$$e_{ij}^{\text{niche}} = [\text{onehot}(r_i), \text{onehot}(r_j), \text{onehot}(n_i), \text{onehot}(n_j), \mathbb{I}(r_i = r_j), \mathbb{I}(n_i = n_j)].$$

如果有组织边界或病理区域注释，则定义 boundary-crossing indicator：

$$b_{ij} = \begin{cases} 1, & r_i \neq r_j, \\ 0, & r_i = r_j. \end{cases}$$

最终边特征为：

$$e_{ij} = [e_{ij}^{\text{sp}}, e_{ij}^{\text{niche}}, b_{ij}].$$

1.8 泄漏控制的空间图 Transformer

空间图 Transformer 用于编码局部生态位上下文和空间传播结构。一个重要问题是信息泄漏：如果在训练或测试时，graph encoder 可以访问 target treated spot 的真实扰动后表达，则模型可能间接看到答案。为避免该问题，本文采用 leakage-controlled graph masking。

对于预测目标集合 $\mathcal{Q}$，其中可以包含 held-out perturbation-labeled spots 或需要反事实预测的 control spots，graph encoder 不允许访问 $\mathcal{Q}$ 中任何 target spot 的真实扰动后表达。

节点初始表示为：

$$h_i^{(0)} = \text{MLP}_{\text{node}}\left([\tilde{z}_i, \text{PE}(s_i), a_i]\right),$$

其中 $\text{PE}(s_i)$ 是空间位置编码，a_i 是可选元数据。

对于非目标节点，$\tilde{z}_i = z_i$。对于目标节点，尤其是 held-out treated spot，其真实扰动后 latent 不得作为输入，而替换为 matched control anchor representation：

$$\tilde{z}_i = \begin{cases} z_i^0, & i \in \mathcal{C}, \\ z_{\text{anchor}(i)}^0, & i \in \mathcal{T}_p^{\text{target}}, \end{cases}$$

其中 $\text{anchor}(i)$ 是根据 d_{match} 找到的 matched control anchor。

在训练时，对于每个 pseudo-pair (i, j)，z_j^p 只作为 residual target 使用，不作为 graph conditioning path 的输入。如果 target treated spot j 出现在图中，则其节点特征被替换为：

$$\tilde{z}_j = z_{\text{anchor}(j)}^0.$$

图 Transformer 第 ℓ 层中，query、key 和 value 定义为：

$$q_i^{(\ell)} = W_Q^{(\ell)} h_i^{(\ell)}, \quad k_j^{(\ell)} = W_K^{(\ell)} h_j^{(\ell)}, \quad v_j^{(\ell)} = W_V^{(\ell)} h_j^{(\ell)}.$$

边特征通过 attention bias 融入：

$$\alpha_{ij}^{(\ell)} = \text{softmax}_{j \in \mathcal{N}(i)} \left(\frac{(q_i^{(\ell)})^\top k_j^{(\ell)}}{\sqrt{d_h}} + \eta^{(\ell)}(e_{ij}) \right),$$

其中 $\eta^{(\ell)}$ 是将边特征映射为 attention bias 的 MLP。

消息聚合为：

$$\tilde{h}_i^{(\ell+1)} = \sum_{j \in \mathcal{N}(i)} \alpha_{ij}^{(\ell)} v_j^{(\ell)}.$$

节点表示更新为：

$$h_i^{(\ell+1)} = \mathrm{FFN}\left(\mathrm{LN}\left(h_i^{(\ell)} + \tilde{h}_i^{(\ell+1)}\right)\right).$$

经过 L 层后，得到空间生态位表示：

$$H = [h_1, \ldots, h_N]^\top \in \mathbb{R}^{N \times d_h}.$$

本文区分两种评估模式：

1. **Inductive mode**：所有目标 treated expression 在图输入中完全 mask，模型仅基于 control state 和空间上下文预测响应；
2. **Transductive mode**：非目标 treated neighbors 可见，但 held-out target spots 仍然 mask。

主结果默认采用 inductive leakage-controlled setting。

1.9 扰动表示与条件注入

对于每个扰动 p，构建扰动嵌入：

$$g_p = f_{\mathrm{pert}}(p).$$

对于基因扰动，扰动嵌入可以结合基因身份、基础表达、GRN 邻域和通路注释：

$$g_p = \mathrm{MLP}_p\left([g_p^{\mathrm{id}}, g_p^{\mathrm{expr}}, g_p^{\mathrm{GRN}}, g_p^{\mathrm{pathway}}]\right).$$

其中 GRN-based embedding 定义为：

$$g_p^{\mathrm{GRN}} = \mathrm{AGG}\left(\{w_{pg} g_g^{\mathrm{id}} : (p,g) \in \mathcal{E}_{\mathrm{GRN}}\}\right),$$

其中 w_{pg} 表示调控边置信度。

扰动信息通过 FiLM 注入空间表示：

$$\gamma_p, \beta_p = \mathrm{MLP}_{\mathrm{FiLM}}(g_p),$$

$$\bar{h}_i = \gamma_p \odot h_i + \beta_p.$$

最终，control spot i 在扰动 p 下的条件向量为：

$$c_i^p = [z_i^0, \bar{h}_i, g_p, \mathrm{PE}(s_i), a_i].$$

1.10 耦合加权的条件潜在残差流

对于 control spot i 和由 coupling 分布 $\pi_p(j \mid i)$ 加权的扰动标记 spot j，目标 residual 为：

$$\Delta z_{ij}^p = z_j^p - z_i^0.$$

本文训练一个条件残差流模型，从高斯噪声生成该 residual。设

$$\epsilon \sim \mathcal{N}(0, I), \quad t \sim \mathcal{U}(0, 1).$$

采用 rectified flow interpolation：

$$\Delta z_t = (1-t)\epsilon + t\Delta z_{ij}^p.$$

目标速度为：

$$u_t = \Delta z_{ij}^p - \epsilon.$$

条件速度网络为：

$$v_\theta(\Delta z_t, t \mid c_i^p).$$

耦合加权 flow matching loss 为：

$$\mathcal{L}_{\text{flow}} = \sum_{i \in \mathcal{C}} \sum_{j \in \mathcal{T}_p(i)} \pi_p(j \mid i) \mathbb{E}_{t,\epsilon} \left[\left\| v_\theta(\Delta z_t, t \mid c_i^p) - (\Delta z_{ij}^p - \epsilon) \right\|_2^2 \right].$$

为了提高可扩展性，内层求和可通过从 $\pi_p(j \mid i)$ 中采样多个 treated spots 近似。
推理时，对于 control spot i 和目标扰动 p，采样

$$\epsilon \sim \mathcal{N}(0, I),$$

并求解 ODE：

$$\frac{d\Delta z_t}{dt} = v_\theta(\Delta z_t, t \mid c_i^p), \quad t : 0 \to 1.$$

得到生成 residual：

$$\widehat{\Delta z_i^p} = \Delta z_{t=1}.$$

预测扰动后的 latent state 为：

$$\hat{z}_i^p = z_i^0 + \widehat{\Delta z_i^p}.$$

最终通过 decoder 重构表达：

$$\hat{x}_i^p = D_\psi(\hat{z}_i^p).$$

1.11 耦合加权重构与分布对齐

由于真实 same-slide unpaired 数据中不存在 x_i^p 这样的同 spot ground truth，本文不将预测结果与某个单一 spot-level target 进行直接监督，而是基于 soft coupling distribution 构建加权表达重构损失：

$$\mathcal{L}_{\text{expr}} = \sum_{i \in \mathcal{C}} \sum_{j \in \mathcal{T}_p(i)} \pi_p(j \mid i) \left[\lambda_1 \|\hat{x}_i^p - x_j^p\|_1 + \lambda_2 \left(1 - \text{PCC}(\hat{x}_i^p, x_j^p)\right) \right].$$

为了进一步对齐预测响应分布和观测扰动分布，在 niche-level 或 mini-batch-level 引入分布对齐损失。对于一个 batch 或生态位组 $\mathcal{B}$，定义预测响应集合：

$$\widehat{\mathcal{X}}_{\mathcal{B}}^p = \{\hat{x}_i^p : i \in \mathcal{B} \cap \mathcal{C}\},$$

对应观测扰动集合：

$$\mathcal{X}_{\mathcal{T}_p(\mathcal{B})} = \{x_j^p : j \in \mathcal{T}_p(\mathcal{B})\}.$$

分布对齐损失定义为 energy distance：

$$\mathcal{L}_{\text{dist}} = D_E \left(\widehat{\mathcal{X}}_{\mathcal{B}}^p, \mathcal{X}_{\mathcal{T}_p(\mathcal{B})} \right),$$

其中

$$D_E(P, Q) = 2\mathbb{E}\|X - Y\| - \mathbb{E}\|X - X'\| - \mathbb{E}\|Y - Y'\|.$$

最终预测损失为：

$$\mathcal{L}_{\text{pred}} = \mathcal{L}_{\text{expr}} + \lambda_{\text{dist}} \mathcal{L}_{\text{dist}}.$$

1.12 边界感知空间正则化

扰动响应在相同组织区域内通常具有局部一致性，但不应在组织边界两侧被过度平滑。因此，本文采用 boundary-aware smoothing。

对于相邻 spot (i, j)，定义：

$$w_{ij}^{\text{intra}} = \exp\left(-\frac{\|s_i - s_j\|_2^2}{\sigma_s^2} \right) (\epsilon_b + 1 - b_{ij}),$$

其中 $b_{ij} = 1$ 表示跨组织边界的边，ϵ_b 为小常数。

空间平滑损失为：

$$\mathcal{L}_{\text{sp}} = \sum_{(i,j) \in \mathcal{E}_{\text{sp}}} w_{ij}^{\text{intra}} \left\| \widehat{\Delta z_i^p} - \widehat{\Delta z_j^p} \right\|_2^2.$$

该损失鼓励同一组织区域内扰动响应局部一致，同时降低跨边界的过度平滑。

如果需要显式建模边界两侧响应差异，可使用 margin loss：

$$\mathcal{L}_{\text{bd}} = \sum_{(i,j) \in \mathcal{E}_{\text{sp}}} b_{ij} \max\left(0, m - \left\| \widehat{\Delta z_i^p} - \widehat{\Delta z_j^p} \right\|_2 \right)^2.$$

主模型中默认仅使用 boundary-aware smoothing，margin loss 作为 ablation 设置。

1.13 生物方向正则化

对于基因扰动，可以可选地使用外部 perturbation signature 或 GRN 先验约束预测表达变化方向。

定义预测表达变化为：

$$\widehat{\Delta x}_{i,g}^{p} = \hat{x}_{i,g}^{p} - x_{i,g}^{0}.$$

若外部 perturbation signature 为响应基因集合 $\mathcal{D}_p$ 提供方向标签

$$s_g^p \in \{-1, +1\},$$

则使用可导的 soft direction loss：

$$\mathcal{L}_{\mathrm{DE}} = \sum_i \sum_{g \in \mathcal{D}_p} \log\left(1 + \exp\left(-\frac{s_g^p \widehat{\Delta x}_{i,g}^{p}}{\tau_{\mathrm{DE}}}\right)\right).$$

对于 GRN 先验，设 $r_{pg} \in \{-1, +1\}$ 表示扰动基因 p 到靶基因 g 的调控方向，其中 $+1$ 表示激活，-1 表示抑制。设扰动类型方向为：

$$d_p = \begin{cases} -1, & \text{knockout, CRISPRi, or inhibition,} \\ +1, & \text{overexpression, CRISPRa, or activation.} \end{cases}$$

则靶基因期望变化方向为：

$$s_{pg} = d_p r_{pg}.$$

GRN 方向损失为：

$$\mathcal{L}_{\mathrm{GRN}} = \sum_i \sum_{g \in \mathcal{T}(p)} \omega_{pg} \log\left(1 + \exp\left(-\frac{s_{pg} \widehat{\Delta x}_{i,g}^{p}}{\tau_{\mathrm{GRN}}}\right)\right),$$

其中 $\mathcal{T}(p)$ 是 perturbation gene 的 GRN target set，ω_{pg} 是边置信度。

这些生物先验正则项仅在可靠 prior 可用时使用，并在 no-prior ablation 中移除。

1.14 生物先验与评价指标的分离

为了避免 circular evaluation，训练、reranking 和评价使用的生物先验必须分离。将生物先验划分为：

$$\mathcal{P}_{\mathrm{train}}, \quad \mathcal{P}_{\mathrm{rerank}}, \quad \mathcal{P}_{\mathrm{eval}}.$$

训练正则化仅使用 $\mathcal{P}_{\mathrm{train}}$，测试时 reranking 仅使用 $\mathcal{P}_{\mathrm{rerank}}$，生物一致性评价仅使用 $\mathcal{P}_{\mathrm{eval}}$。

对于 GRN，可按 target genes 或 regulatory edges 进行划分；对于 perturbation signatures，可将部分响应基因从训练和 reranking 中排除，仅用于评价；对于 pathway analysis，训练或 reranking 中使用过的 pathway 不再作为评价通路。

本文报告以下模型变体：

1. 不使用任何生物先验；

2. 仅使用训练阶段先验；

3. 仅使用测试阶段 reranking 先验；

4. 同时使用训练先验和 reranking 先验。

该设计用于区分真正的预测能力提升与直接优化评价指标造成的虚假提升。

1.15 总体训练目标

最终训练目标为：

$$\mathcal{L} = \mathcal{L}_{\text{flow}} + \lambda_{\text{pred}}\mathcal{L}_{\text{pred}} + \lambda_{\text{sp}}\mathcal{L}_{\text{sp}} + \lambda_{\text{DE}}\mathcal{L}_{\text{DE}} + \lambda_{\text{GRN}}\mathcal{L}_{\text{GRN}}.$$

其中 $\mathcal{L}_{\text{flow}}$ 是耦合加权 residual flow matching loss，$\mathcal{L}_{\text{pred}}$ 是耦合加权表达重构与分布对齐损失，$\mathcal{L}_{\text{sp}}$ 是边界感知空间平滑损失，$\mathcal{L}_{\text{DE}}$ 和 $\mathcal{L}_{\text{GRN}}$ 是可选生物方向正则项。

训练分为三个阶段：

1. 使用所有可用 spot 预训练表达 VAE 或 autoencoder；

2. 构建扰动不变 matching representation，并生成 same-slide pseudo-counterfactual coupling；

3. 在 leakage-controlled graph input 下，联合训练空间图 Transformer 和条件 residual flow。

1.16 测试阶段生物 reranking

训练好的 residual flow 定义了扰动响应场的生成先验：

$$p_\theta(\widehat{\Delta Z}^p \mid Z^0, H, g_p, S).$$

由于多个扰动响应场都可能合理，本文可选地进行 Best-of-K reranking。对于目标 control 区域，生成 K 个候选响应场：

$$\{\hat{X}^{p,(1)}, \ldots, \hat{X}^{p,(K)}\}.$$

定义生物 reward：

$$R_{\text{bio}}(\hat{X}^p) = \lambda^R_{\text{DE}} R_{\text{DE}} + \lambda^R_{\text{GRN}} R_{\text{GRN}}.$$

扰动 signature reward 为：

$$R_{\text{DE}} = \text{corr}\left(\widehat{\Delta x}^p_{\mathcal{D}_p}, \Delta x^p_{\text{prior},\mathcal{D}_p}\right).$$

为了避免 GRN reward unbounded 导致 reward hacking，采用 bounded GRN reward：

$$R_{\text{GRN}} = \frac{1}{|\mathcal{C}|}\sum_{i\in\mathcal{C}}\sum_{g\in\mathcal{T}(p)} \omega_{pg}\tanh\left(\frac{s_{pg}\widehat{\Delta x}^p_{i,g}}{\sigma_g + \epsilon}\right),$$

其中 σ_g 是基因 g 的表达变化尺度估计，ϵ 为数值稳定项。

最终预测选择为：

$$\hat{X}^{p,*} = \arg \max_{k \in \{1,\dots,K\}} R_{\text{bio}}(\hat{X}^{p,(k)}).$$

该 reranking 不是基础模型的必要组成部分，仅作为可靠生物先验可用时的推理阶段增强。

1.17 不确定性估计

由于模型是生成式的，可通过多次采样估计预测不确定性：

$$\hat{X}^{p,(1)}, \dots, \hat{X}^{p,(K)}.$$

平均预测为：

$$\bar{X}^p = \frac{1}{K} \sum_{k=1}^{K} \hat{X}^{p,(k)}.$$

基因水平不确定性为：

$$U_{i,g} = \text{Var}_k \left(\hat{x}_{i,g}^{p,(k)} \right).$$

spot 水平不确定性为：

$$U_i = \frac{1}{G} \sum_{g=1}^{G} U_{i,g}.$$

高不确定性可能对应稀有生态位、弱匹配 control–treated 分布、组织边界区域或跨生态位外推区域。

1.18 评价协议

本文区分两类评价设定。

Paired、registered 或 simulated benchmark。 如果存在真实 spot-level counterfactual，例如模拟扰动数据或配准后的近似成对切片，则可以报告 spot-level 指标：

$$\text{MAE} = \frac{1}{NG} \sum_{i=1}^{N} \sum_{g=1}^{G} |\hat{x}_{i,g}^{p} - x_{i,g}^{p}|.$$

同时报告 Pearson correlation：

$$\text{PCC} = \text{corr}(\text{vec}(\hat{X}^p), \text{vec}(X^p)).$$

真实 same-slide unpaired benchmark。 对于真实 same-slide spatial perturbation data，不存在真实的 spot-level counterfactual，因此 spot-level MAE 和 PCC 不作为主指标。本文采用 leakage-controlled held-out perturbation distribution evaluation。

首先从扰动标记集合中划分测试集：

$$\mathcal{T}_p^{\text{test}} \subset \mathcal{T}_p.$$

这些 held-out treated spots 的真实扰动后表达在 graph input 中被 mask，只用于最终评价。然后为 held-out treated set 定义 matched control anchors：

$$\mathcal{C}^{\text{test}} = \{\text{anchor}(j) : j \in \mathcal{T}_p^{\text{test}}\},$$

其中

$$\text{anchor}(j) = \arg\min_{i \in \mathcal{C}} d_{\text{match}}(i, j).$$

模型从 $\mathcal{C}^{\text{test}}$ 生成预测扰动分布：

$$\widehat{\mathcal{X}}_p^{\text{test}} = \{\hat{x}_i^p : i \in \mathcal{C}^{\text{test}}\}.$$

观测到的 held-out treated distribution 为：

$$\mathcal{X}_p^{\text{test}} = \{x_j^p : j \in \mathcal{T}_p^{\text{test}}\}.$$

主评价指标为 energy distance：

$$D_E\left(\widehat{\mathcal{X}}_p^{\text{test}}, \mathcal{X}_p^{\text{test}}\right) = 2\mathbb{E}\|X - Y\| - \mathbb{E}\|X - X'\| - \mathbb{E}\|Y - Y'\|,$$

其中 X, X' 为预测样本，Y, Y' 为 held-out observed perturbed samples。

同时报告 niche-stratified energy distance：

$$D_E^{(r,n)} = D_E\left(\widehat{\mathcal{X}}_{p,r,n}^{\text{test}}, \mathcal{X}_{p,r,n}^{\text{test}}\right),$$

其中 (r, n) 表示组织区域和生态位。

此外，评价以下生物一致性指标：

1. held-out perturbation signature 上的 DE direction agreement；

2. 未在训练或 reranking 中使用的 pathway enrichment agreement；

3. held-out GRN edges 上的 GRN target enrichment；

4. marker genes 的空间模式相似性；

5. 多次采样预测的不确定性校准。

1.19 预测任务

本文评估四类空间扰动预测任务：

Patch prediction。 给定一个未扰动局部区域，预测其在附近或匹配组织上下文中观测到的扰动下的响应。

Border prediction。 评估组织边界附近 spot 的预测能力，因为此处扰动响应可能出现急剧变化。

Niche prediction。 扰动周围生态位并预测中心区域响应，用于检验模型是否捕获微环境介导的扰动效应。

Cross-niche prediction。 当目标生态位中没有该扰动的训练样本时，预测其扰动响应。该任务被视为强外推任务。具体采用 leave-one-niche-out protocol：训练时排除目标 niche 中的 perturbation-labeled spots，仅在测试时使用这些 held-out spots 进行分布评价。

1.20 Baseline 与消融实验

本文与以下 baseline 比较：

1. **kNN-SP**：基于空间坐标的最近邻响应转移；
2. **kNN-GEX**：基于表达或 latent 表示的最近邻响应转移；
3. **Mean response**：区域或生态位水平平均扰动响应转移；
4. **scGEN**：非空间 latent perturbation prediction 模型；
5. **CPA**：compositional perturbation autoencoder；
6. **CellOT**：基于最优传输的扰动预测模型；
7. **GCN/GAT predictor**：确定性空间图神经网络回归模型；
8. **CONCERT**：已有 niche-aware spatial perturbation generative baseline；
9. **Ours without perturbation-invariant matching**：直接使用 response latent 进行 matching；
10. **Ours without matching**：随机 control–treated pairing；
11. **Ours without graph**：移除空间图 Transformer；
12. **Ours without flow**：使用确定性 MLP residual regression；

13. **Ours without biological priors**：不使用 DE 或 GRN 正则；

14. **Ours without reranking**：仅使用基础生成模型。

消融实验包括：

1. 将扰动不变 matching 替换为 response latent matching；
2. 将 soft matching 替换为 random matching；
3. 将 soft matching 替换为 optimal transport coupling；
4. 移除空间图 Transformer；
5. 将 graph Transformer 替换为 GCN、GAT 或 GraphSAGE；
6. 移除扰动 FiLM conditioning；
7. 移除 boundary-aware spatial regularization；
8. 移除 DE direction regularization；
9. 移除 GRN direction regularization；
10. 将 latent flow 替换为 deterministic residual regression；
11. 移除 Best-of-K biological reranking；
12. 比较 inductive 和 transductive graph evaluation。

1.21 实现细节

默认设置中，表达 latent dimension 设为 $d_z = 64$ 或 128。空间图使用 $k = 8$ 至 16 个最近邻构建。图 Transformer 包含 2 至 4 层，每层 4 至 8 个 attention heads。扰动嵌入维度设为 128。

残差流 velocity network 可实现为 MLP 或轻量 Transformer，输入包括 time embedding、control latent state、空间图表示和 perturbation embedding。时间变量 t 使用 sinusoidal embedding 编码。

same-slide matching 中的 temperature τ 以及 matching weights $\alpha_u, \alpha_s, \alpha_r, \alpha_n, \alpha_q$ 通过 validation set 选择。Best-of-K reranking 默认生成 $K = 16$ 至 64 个候选响应场，reranking reward weights 在 validation perturbations 上选择并在测试时固定。

所有训练、验证和测试划分均遵守 leakage control：held-out perturbation-labeled spots 的真实扰动后表达不得作为 graph input，只能用于最终评价。

2 方法贡献总结

本文方法与已有空间扰动预测方法相比，主要贡献包括：

1. **不假设 spot-level before–after pairing**：显式处理 same-slide unpaired spatial perturbation data；
2. **扰动不变生态位匹配**：使用 baseline-like tissue identity 构建 control–treated coupling，避免直接用扰动后表达进行 matching；
3. **潜在残差流生成模型**：将扰动响应建模为 latent residual distribution，而不是确定性 spot-wise regression；
4. **泄漏控制的空间图建模**：训练和测试中均避免 held-out treated expression 泄漏到 graph conditioning；
5. **分布级评价协议**：真实 same-slide 数据中采用 held-out perturbation distribution evaluation，而非不可获得的 spot-level counterfactual metrics；
6. **可选生物先验增强**：DE、GRN 和 pathway prior 可用于训练正则或测试 reranking，但与评价先验严格分离。